

# 회귀분석(Regression Analysis)

○정우

phyjics@gmail.com

2019년 9월 16일

## 차 례

차 례	1
제 1 장 최소 제곱법(Least Squares Fitting)	2
1.1 선형 회귀 - 직선 . . . . .	2
1.2 함수를 알고 있는 경우 . . . . .	2
제 2 장 원 피팅	4
2.1 리만 피팅 . . . . .	4
2.1.1 극사영 . . . . .	4
2.1.2 리만 구 위의 원 . . . . .	4
2.1.3 역 극사영 . . . . .	5
2.1.4 역 극사영 초콜릿 먹고싶다 . . . . .	6
2.2 간단한 원 피팅 . . . . .	6
제 3 장 수직 거리 회귀(Orthogonal Distance Regression (ODR))를 이용한 최소 제곱법	9
3.1 평면 피팅 . . . . .	9
3.2 가만있어봐라 . . . . .	11
3.3 직선 피팅 . . . . .	14
제 4 장 수직 거리 회귀와 Stereographic projection을 이용한 원 피팅	15
4.1 Stereographic projection . . . . .	15
4.2 원 파라미터 . . . . .	15
참고 문헌	17

# 제 1 장

## 최소 제곱법(Least Squares Fitting)

### 1.1 선형 회귀 - 직선

N개의 데이터 점  $(x_i, y_i)$ 이 직선

$$f(x) = ax + b, \quad (1.1)$$

의 분포를 따른다고 할 때 최소 제곱법은 데이터와 직선 사이의  $y$ 값 차이를 제곱하여 합한 값을 최소화 하는 방법이다. 최소화 하고자 하는 값  $S$ 는 다음과 같다.

$$S = \sum_{i=1}^N (y_i - ax_i - b)^2. \quad (1.2)$$

이를 변수  $a$ 와  $b$ 에 대해서 각각 최소화 하면;

$$\frac{\partial S}{\partial a} = 0, \quad \frac{\partial S}{\partial b} = 0, \quad (1.3)$$

아래와 같이  $a$ 와  $b$ 를 구할 수 있다.

$$a = \frac{\langle x_i y_i \rangle - \langle x_i \rangle \langle y_i \rangle}{\langle x_i^2 \rangle - \langle x_i \rangle^2}. \quad (1.4)$$

$$b = \frac{\langle x_i^2 \rangle \langle y_i \rangle - \langle x_i \rangle \langle x_i y_i \rangle}{\langle x_i^2 \rangle - \langle x_i \rangle^2}. \quad (1.5)$$

### 1.2 함수를 알고 있는 경우

N개의 데이터 점  $(x_i, y_i)$ 이

$$f(x) = av(x - b), \quad (1.6)$$

의 분포를 따른다고 할 때 최소화 하고자 하는  $S$ 는

$$S = \sum_{i=1}^N (y_i - av(x_i - b))^2, \quad (1.7)$$

이 된다. 이를  $a$ 와  $b$ 에 대해서 최소화 하면 ( $\partial S / \partial a = 0, \partial S / \partial b = 0$ ) 다음과 같다.

$$\frac{\partial S}{\partial a} = 0 \rightarrow a = \frac{\sum y_i v(x_i - b)}{\sum f^2(x_i - b)}. \quad (1.8)$$

함수의 형태를 알지 못할 때 변수  $b$ 는 함수  $v$ 에 종속되어 있어 구할 수 없다. 하지만 특정  $b$ 에서 최소 제곱 법에 맞는  $a$ 를 구할 수 있다. 함수의 형태를 알고 있을 때는 경우에 따라 다음 식을 이용하여  $b$ 를 구할 수 있다.

$$\frac{\partial s}{\partial b} = 0 \quad \longrightarrow \quad a = \frac{\sum y_i v'(x_i - b)}{\sum v(x_i - b)v'(x_i - b)} \quad (1.9)$$

$$v'(x) \equiv \frac{\partial v(x)}{\partial x} \quad (1.10)$$

## 제 2 장

# 원 피팅

### 2.1 리만 피팅

#### 2.1.1 극사영

극사영은(stereographic projection)은 구면의 점을 평면으로, 또는 반대로 옮기는 합수이며 입체사영(conformal mapping)으로도 불린다.  $(x, z)$  평면위의 점  $P_i(x_i, 0, z_i)$ 와, 원점  $O(0, 0, 0)$  위에 놓인 리만 구(Riemann sphere)  $S$ 를 생각해보자. 이 구는  $R$ 의 반지름을 가지며 중심점  $C$ 는  $(0, R, 0)$ 로 주어진다.

$$S : x^2 + (y - R)^2 + z^2 = R^2 \quad (2.1)$$

점  $P_i$ 에서 리만 구의 꼭지점  $T(0, 2R, 0)$ 를 잇는 선이 구와 만나는 점을  $P'_i(x'_i, y'_i, z'_i)$ 라고 하자. 반지름  $r_i$ 를  $r_i \equiv \sqrt{x_i^2 + z_i^2}/2R$  와 같이 정의 하였을 때 점  $P'_i$ 는 점  $P_i$ 로부터 다음과 같이 주어진다.

$$\begin{aligned} x'_i &= \frac{x_i}{1 + r_i^2} \\ y'_i &= \frac{2Rr_i^2}{1 + r_i^2} \\ z'_i &= \frac{z_i}{1 + r_i^2} \end{aligned} \quad (2.2)$$

반대로 점  $P_i$ 는 점  $P'_i$ 로부터 다음과 같이 주어진다.

$$\begin{aligned} x_i &= \frac{x'_i}{1 - y'_i/2R} \\ z_i &= \frac{z'_i}{1 - y'_i/2R} \end{aligned} \quad (2.3)$$

#### 2.1.2 리만 구 위의 원

리만 구 위에 사영된 데이터 점  $P'_i$ 을 평면으로 피팅을 하였을 때(3.1절 참조) 구해진 평면  $K$ 의 수직 벡터를  $\mathbf{n}(a, b, c)$ , 평면에 속한 한점( $P'_i$ 의 평균)을  $M(\langle x \rangle', \langle y \rangle', \langle z \rangle')$ 이라 하자.

$$K : a(x - \langle x \rangle') + b(y - \langle y \rangle') + c(z - \langle z \rangle') = 0 \quad (2.4)$$

평면이 구를 자르면서 생기는 원의 중심점 A는 리만구의 중심점 C를 지나고  $\mathbf{n}$ 의 방향을 가진 직선 L이 평면 K와 만나는 점이 된다.

$$L : \begin{cases} x = at \\ y = bt + R \\ z = ct \end{cases} \quad (2.5)$$

연립하여 풀면 중심점에서의 t인  $t_A$ 는 다음과 같고

$$t_A = \frac{a\langle x \rangle' + b(\langle y \rangle' - R) + c\langle z \rangle'}{a^2 + b^2 + c^2}, \quad (2.6)$$

원의 중심점  $C_A$ 는  $(at_A, bt_A + R, ct_A)$ 이 되며 리만 구의 중심에어 원의 중심까지의 거리가  $l = |\overline{CC}_A|$  일때 원의 반지름  $r_A$ 는  $\sqrt{R^2 - l^2}$ 이 된다.

### 2.1.3 역 극사영

원 A를  $xz$ 평면 위에 뉘고( $A_\perp, \mathbf{x}_\perp$ )

$$A_\perp : x_\perp^2 + z_\perp^2 = r_A^2 \quad (2.7)$$

벡터  $\hat{\mathbf{y}}$ 가 피팅한 평면의 수직벡터  $\mathbf{n}$ 과 같도록 회전시킨 후  $y$  방향으로  $(C_A)_y$  만큼 올린 원이 된다. 회전 행렬  $\mathbf{R}$ 을  $x$ 축,  $y$ 축으로 분리해서 보자.

$$\mathbf{R} = \mathbf{R}_y(\phi)\mathbf{R}_x(\theta), \quad (2.8)$$

$$\mathbf{R}_y(\phi) = \begin{pmatrix} \cos \phi & 0 & \sin \phi \\ 0 & 1 & 0 \\ -\sin \phi & 0 & \cos \phi \end{pmatrix}, \quad \mathbf{R}_x(\theta) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos \theta & -\sin \theta \\ 0 & \sin \theta & \cos \theta \end{pmatrix} \quad (2.9)$$

이 회전은  $\hat{\mathbf{y}}$ 가  $\mathbf{n}$ 가 되는 회전과 같다.

$$\mathbf{x}' = \mathbf{R}\mathbf{x}_\perp \longrightarrow \mathbf{R}\hat{\mathbf{y}} = \mathbf{n}, \quad (2.10)$$

따라서 다음과 같이 행렬의 각 성분들을 구할 수 있다.

$$\begin{aligned} \cos \theta &= b \\ \sin \theta &= d \\ \cos \phi &= c/d \\ \sin \phi &= a/d \end{aligned}, \quad d \equiv \sqrt{1 - b^2} \quad (2.11)$$

이 되고  $\mathbf{R}$ ,  $\mathbf{R}^{-1}$ 과 변환 식은 다음과 같이 쓸 수 있다.

$$\mathbf{R} = \begin{pmatrix} c/d & a & ab/d \\ 0 & b & -d \\ -a/d & c & bc/d \end{pmatrix}, \quad \mathbf{R}^{-1} = \begin{pmatrix} c/d & 0 & -a/d \\ a & b & c \\ ab/d & -d & bc/d \end{pmatrix} \quad (2.12)$$

$$\mathbf{x}_\perp \rightarrow \mathbf{x}' \quad \begin{cases} x' = (c/d)x_\perp + ay_\perp + (ab/d)z_\perp \\ y' = by_\perp - dz_\perp \\ z' = -(a/d)x_\perp + cy_\perp + (bc/d)z_\perp \end{cases} \quad (2.13)$$

$$\mathbf{x}' \rightarrow \mathbf{x}_\perp \quad \begin{cases} x_\perp = (c/d)x' - (a/d)z' \\ y_\perp = ax' + by' + cz' \\ z_\perp = (ab/d)x' - dy' + (bc/d)z' \end{cases} \quad (2.14)$$

원  $A_\perp$ 를 변환식을 통하여 치환하고  $y$  방향으로  $(C_A)_y$  만큼 올리면 다음과 같다.

$$(cx' - az')^2 + (abx' - d^2(y' - (C_A)_y) + bcz')^2 = r_A^2 d^2 \quad (2.15)$$

다음으로 식 (2.2) 을 이용하여 리만구의 원을  $xz$  평면으로 옮겨 보자.

$$(cx - az)^2 + (abx - d^2(2Rr^2 - (1+r^2)(C_A)_y) + bcz)^2 = (r_A d(1+r^2))^2 \quad (2.16)$$

그런데 이렇게 계산하다보면 끝이 나지 않는다! 이럴수가! 살려줘!

#### 2.1.4 역 극사영 초콜릿 먹고싶다

작전은 이렇다. 원  $A$ 에서  $y$  값이 가장 작은 점과 가장 큰 점을 구해서 역 극사영 시킨다. 이 두점은 역 극사영 된 후에도 서로 원의 정 반대편에 위치하므로  $xz$  평면에서의 최종 원을 쉽게 구할 수 있다. 중심점은 두 점의 중간지점이고 반지름은 두 점 사이 거리의 반이다! 오! 된다! 코딩해봤더니 됩니다!

$$\mathbf{R}' = \mathbf{R}_y(\phi)\mathbf{R}_x(\alpha), \quad (2.17)$$

$$\mathbf{R}_y(\phi) = \begin{pmatrix} \cos \phi & 0 & \sin \phi \\ 0 & 1 & 0 \\ -\sin \phi & 0 & \cos \phi \end{pmatrix}, \quad \mathbf{R}_x(\alpha) = \begin{pmatrix} 1 & 0 & 0 \\ 0 & \cos \alpha & -\sin \alpha \\ 0 & \sin \alpha & \cos \alpha \end{pmatrix} \quad (2.18)$$

$$\begin{aligned} \cos \alpha &= l/R \\ \sin \alpha &= r_A/R \end{aligned} \quad (2.19)$$

## 2.2 간단한 원 피팅

가중치  $w_i$ 를 가지고 있는 N개의 데이터 점  $(x_i, y_i)$ 의 원

$$(x - x_c)^2 + (y - y_c)^2 = r^2, \quad (2.20)$$

의 분포를 따른다고 하자. 원의 반지름  $r$  제곱과 원의 중심에서 데이터 점 까지의 거리 제곱의 차이의 제곱을 모두 합한 값을 최소화 해보자. 즉, 다음 S를 최소화 한다.

$$\Lambda_i(x_c, y_c, r) = r^2 - [(x_i - x_c)^2 + (y_i - y_c)^2] \quad (2.21)$$

$$S(x_c, y_c, r) = \sum_{i=1}^N w_i \Lambda_i^2 \quad (2.22)$$

이때 식 (2.21)의  $x$ 와  $y$ 는 데이터의 기대값 만큼 평행 이동한  $u(=x-\langle x \rangle)$ 과  $v(=y-\langle y \rangle)$ 로 다시 쓸 수 있다.

$$\Lambda_i(u_c, v_c, r) = r^2 - [(x_i - x_c)^2 + (y_i - y_c)^2] \quad (2.23)$$

$$\begin{aligned} &= r^2 - [(x_i - \langle x \rangle - x_c + \langle x \rangle)^2 + (y_i - \langle y \rangle - y_c + \langle y \rangle)^2] \\ &= r^2 - [((x_i - \langle x \rangle) - (x_c - \langle x \rangle))^2 + ((y_i - \langle y \rangle) - (y_c - \langle y \rangle))^2] \\ &= r^2 - [(u_i - u_c)^2 + (v_i - v_c)^2] \quad (2.24) \\ &= r^2 - u_i^2 - u_c^2 + 2u_i u_c - v_i^2 - v_c^2 + 2v_i v_c. \end{aligned}$$

이제 각 변수에 대해서 최소화 해보자.

$$\frac{\partial S}{\partial r} = 0 \longrightarrow \sum_i^N w_i \Lambda_i = 0 \quad (2.25)$$

$$\frac{\partial S}{\partial u_c} = 0 \longrightarrow \sum_i^N w_i u_i \Lambda_i = 0 \quad (2.26)$$

$$\frac{\partial S}{\partial v_c} = 0 \longrightarrow \sum_i^N w_i v_i \Lambda_i = 0 \quad (2.27)$$

식 (2.25)를  $W$ 로 나눈 후 풀어쓰면 다음과 같다.

$$\begin{aligned} \frac{1}{W} \sum_i^N w_i \Lambda_i &= \frac{1}{W} \sum_i^N w_i (r^2 - u_i^2 - u_c^2 + 2u_i u_c - v_i^2 - v_c^2 + 2v_i v_c) \\ &= r^2 - \langle u^2 \rangle - u_c^2 + 2u_c \langle u \rangle - \langle v^2 \rangle - v_c^2 + 2v_c \langle v \rangle \\ &= r^2 - (u_c^2 + v_c^2) - \langle u^2 \rangle - \langle v^2 \rangle = 0 \end{aligned} \quad (2.28)$$

위 계산은  $\langle u \rangle = 0$ ,  $\langle v \rangle = 0$  임을 이용하였다. 위 식을 이용하면 반지름의 제곱은 다음과 같이 구해진다.

$$r^2 = u_c^2 + v_c^2 + \langle u^2 \rangle + \langle v^2 \rangle. \quad (2.29)$$

식 (2.26)과 식 (2.27)은 다음과 같이 나타난다.

$$\begin{aligned} \frac{1}{W} \sum_i^N w_i u_i \Lambda_i &= \frac{1}{W} \sum_i^N w_i u_i (r^2 - u_i^2 - u_c^2 + 2u_i u_c - v_i^2 - v_c^2 + 2v_i v_c) \\ &= r^2 \langle u \rangle - \langle u^3 \rangle - u_c^2 \langle u \rangle + 2u_c \langle u^2 \rangle - \langle uv^2 \rangle - v_c^2 \langle u \rangle + 2v_c \langle uv \rangle \\ &= -\langle u^3 \rangle + 2u_c \langle u^2 \rangle - \langle uv^2 \rangle + 2v_c \langle uv \rangle = 0 \end{aligned} \quad (2.30)$$

$$\frac{1}{W} \sum_i^N w_i v_i \Lambda_i = -\langle u^2 v \rangle + 2u_c \langle uv \rangle - \langle v^3 \rangle + 2v_c \langle v^2 \rangle = 0 \quad (2.31)$$

즉, 다음과 같은 연립 방정식이 나오며

$$2\langle u^2 \rangle u_c + 2\langle uv \rangle v_c = \langle u^3 \rangle + \langle uv^2 \rangle \quad (2.32)$$

$$2\langle uv \rangle u_c + 2\langle v^2 \rangle v_c = \langle u^2 v \rangle + \langle v^3 \rangle \quad (2.33)$$

행렬 식으로 쓰면,

$$\begin{pmatrix} \langle u^2 \rangle & \langle uv \rangle \\ \langle uv \rangle & \langle v^2 \rangle \end{pmatrix} \begin{pmatrix} u_c \\ v_c \end{pmatrix} = \frac{1}{2} \begin{pmatrix} \langle u^3 \rangle + \langle uv^2 \rangle \\ \langle u^2 v \rangle + \langle v^3 \rangle \end{pmatrix} \quad (2.34)$$

$$\begin{pmatrix} u_c \\ v_c \end{pmatrix} = \frac{1}{2} \frac{1}{\langle u^2 \rangle \langle v^2 \rangle - \langle uv \rangle^2} \begin{pmatrix} \langle v^2 \rangle & -\langle uv \rangle \\ -\langle uv \rangle & \langle u^2 \rangle \end{pmatrix} \begin{pmatrix} \langle u^3 \rangle + \langle uv^2 \rangle \\ \langle u^2 v \rangle + \langle v^3 \rangle \end{pmatrix} \quad (2.35)$$

와 같고 풀어쓰면 다음과 같다.

$$u_c = \frac{1}{2} \frac{\langle v^2 \rangle (\langle u^3 \rangle + \langle uv^2 \rangle) - \langle uv \rangle (\langle u^2 v \rangle + \langle v^3 \rangle)}{\langle u^2 \rangle \langle v^2 \rangle - \langle uv \rangle^2} \quad (2.36)$$

$$v_c = \frac{1}{2} \frac{\langle u^2 \rangle (\langle u^2 v \rangle + \langle v^3 \rangle) - \langle uv \rangle (\langle u^3 \rangle + \langle uv^2 \rangle)}{\langle u^2 \rangle \langle v^2 \rangle - \langle uv \rangle^2} \quad (2.37)$$

데이터가 완벽한 직선을 이룬다면  $\langle u^2 \rangle \langle v^2 \rangle - \langle uv \rangle^2 = 0$  이 되면서 해가 없지만, 이 경우를 제외하면 원의 중심은 다음과 같이 주어진다.

$$x_c = \frac{1}{2} \frac{\langle v^2 \rangle (\langle u^3 \rangle + \langle uv^2 \rangle) - \langle uv \rangle (\langle u^2 v \rangle + \langle v^3 \rangle)}{\langle u^2 \rangle \langle v^2 \rangle - \langle uv \rangle^2} + \langle x \rangle \quad (2.38)$$

$$y_c = \frac{1}{2} \frac{\langle u^2 \rangle (\langle u^2 v \rangle + \langle v^3 \rangle) - \langle uv \rangle (\langle u^3 \rangle + \langle uv^2 \rangle)}{\langle u^2 \rangle \langle v^2 \rangle - \langle uv \rangle^2} + \langle y \rangle \quad (2.39)$$

제곱평균제곱근(Root Mean Square)은 그냥 계산...

$$\text{RMS} = \sqrt{\frac{\sum_i^N w_i \Lambda_i^2}{\langle w \rangle_N (N-3)}} \quad (2.40)$$

## 제 3 장

# 수직 거리 회귀(Orthogonal Distance Regression (ODR))를 이용한 최소 제곱법

### 3.1 평면 피팅

3차원에서 주어진 N개의 점 데이터를 이용하여 가장 잘 맞는 평면을 피팅해보자. 이 문서에서 다룰 평면 피팅은 ODR(수직 거리 회귀, Orthogonal Distance Regression) 피팅으로 각 점에서 평면까지 수직 거리 제곱의 합을 최소화 하는 방법이다. 일반적인 피팅 방법에서는 문제에서 최소화 할  $S$ 를 정한 뒤 변수를 바꿔가면서  $S$ 가 최소가 되는 점을 찾아 나가는 반복 계산을 한다. 하지만 ODR 피팅은  $S$ 가 최소가 되는 지점을 3차원 행렬의 고윳값 문제로 해결 할 수 있다는 것이 증명되어 있다. 또한 이 방법으로 평면 피팅 뿐만 아니라 선 피팅도 할 수 있다.

$N$ 개의 점 데이터를 평면( $ax + by + cz + d = 0$ )으로 피팅을 하고 싶다.  $i$ 번째 점의 가중치는  $w_i$ 이며 위치는  $(x_i, y_i, z_i)$ 로 주어진다. 평면과  $i$ 번째 점 사이의 수직 거리는 다음과 같다.

$$D_i(a, b, c, d) = \frac{|ax_i + by_i + cz_i + d|}{\sqrt{a^2 + b^2 + c^2}}. \quad (3.1)$$

$N$ 개의 점에 대해서 가중치를 고려한 거리 제곱  $D_i^2$ 의 합은 다음과 같다.

$$\begin{aligned} S(a, b, c, d) &= \sum_{i=1}^N w_i D_i(a, b, c, d)^2 \\ &= \sum_{i=1}^N w_i \frac{|ax_i + by_i + cz_i + d|^2}{a^2 + b^2 + c^2}. \end{aligned} \quad (3.2)$$

$S$ 를 변수  $d$ 에 대해서 최소화 하면  $\partial S / \partial d = 0$  이므로 다음을 얻는다.

$$d = - \left( a \langle x \rangle_N + b \langle y \rangle_N + c \langle z \rangle_N \right). \quad (3.3)$$

여기서  $\langle x \rangle_N, \langle y \rangle_N, \langle z \rangle_N$ 는 N개 데이터에 대한 기댓값이고

$$\langle x \rangle_N \equiv \frac{1}{W_N} \sum_{i=1}^N w_i x_i \quad (3.4)$$

$$\langle y \rangle_N \equiv \frac{1}{W_N} \sum_{i=1}^N w_i y_i \quad (3.5)$$

$$\langle z \rangle_N \equiv \frac{1}{W_N} \sum_{i=1}^N w_i z_i \quad (3.6)$$

$W$ 는 가중치의 합이다.

$$W_N = \sum_{i=1}^N w_i. \quad (3.7)$$

식 (3.3)을 평면의 방정식에 대입하면 다음과 같다.

$$a(x_i - \langle x \rangle_N) + b(y_i - \langle y \rangle_N) + c(z_i - \langle z \rangle_N) = 0. \quad (3.8)$$

즉, 우리가 구하려고 하는 평면은 반드시 데이터의 중심점을 지나간다는 사실을 알 수 있다. 나아가 식 (3.2)는

$$\begin{aligned} S(a, b, c) &= \sum_{i=1}^N w_i \frac{|ax_i + by_i + cz_i - a\langle x \rangle_N - b\langle y \rangle_N - c\langle z \rangle_N|^2}{a^2 + b^2 + c^2} \\ &= \sum_{i=1}^N \frac{|a\sqrt{w_i}(x_i - \langle x \rangle_N) + b\sqrt{w_i}(y_i - \langle y \rangle_N) + c\sqrt{w_i}(z_i - \langle z \rangle_N)|^2}{a^2 + b^2 + c^2} \\ &= \sum_{i=1}^N \frac{|aX_{N,i} + bY_{N,i} + cZ_{N,i}|^2}{a^2 + b^2 + c^2} \end{aligned} \quad (3.9)$$

이 된다.  $X_{N,i}, Y_{N,i}, Z_{N,i}$ 는 다음과 같이 정의한다.

$$X_{N,i} \equiv \sqrt{w_i} (x_i - \langle x \rangle_N) \quad (3.10)$$

$$Y_{N,i} \equiv \sqrt{w_i} (y_i - \langle y \rangle_N) \quad (3.11)$$

$$Z_{N,i} \equiv \sqrt{w_i} (z_i - \langle z \rangle_N) \quad (3.12)$$

이제  $S$ 를 행렬식으로 쓰면

$$\mathbf{v}^T \equiv (a, b, c), \quad (3.13)$$

$$\mathbf{M} \equiv \begin{pmatrix} X_1 & Y_1 & Z_1 \\ X_2 & Y_2 & Z_2 \\ X_3 & Y_3 & Z_3 \\ \vdots & \vdots & \vdots \\ X_N & Y_N & Z_N \end{pmatrix}, \quad (3.14)$$

일때 다음과 같이 다시 쓸 수 있다.

$$S(\mathbf{v}) = \frac{\mathbf{v}^T \mathbf{M}^T \mathbf{M} \mathbf{v}}{\mathbf{v}^T \mathbf{v}} = \frac{\mathbf{v}^T \mathbf{A} \mathbf{v}}{\mathbf{v}^T \mathbf{v}}. \quad (3.15)$$

$$\mathbf{A} \equiv \mathbf{M}^T \mathbf{M} \quad (3.16)$$

$S(\mathbf{v})$ 는 Rayleigh Quotient로 행렬  $\mathbf{A}$ 의 가장 작은 고윳값(eigen value)을 택하였을 때 최소화 되며, 반대로 가장 큰 고윳값을 택하였을 때 최대화 된다. 이때 고유벡터(eigen vector)  $\mathbf{v}$ 는 평면의 수직 벡터가 된다.

행렬  $\mathbf{M}$ 에 대해서 특이값 분해(Singular value decomposition)를 하고 이를 행렬  $\mathbf{A}$ 에 대입하면

$$\mathbf{M} = \mathbf{U} \mathbf{S} \mathbf{V}^T \quad (3.17)$$

$$\mathbf{A} = \mathbf{V} \mathbf{S}^2 \mathbf{V}^T \quad (3.18)$$

가 된다. 즉 행렬  $\mathbf{A}$ 의 고윳값은 행렬  $\mathbf{M}$ 의 특이값의 제곱이 되며 행렬  $\mathbf{A}$ 의 고유벡터는 행렬  $\mathbf{M}$ 의 특이벡터와 같다. 여기서 특이값을 구하거나 고윳값을 구하므로써 평면을 구할 수 있는데 아직 특이값에 대해 자세히 알지 못하므로 어느 방법이 더 좋은지 알 수 없다(추가 바람). 따라서 지금은 행렬  $\mathbf{A}$ 의 고윳값 문제로 해결하도록 한다.

식 (3.18)에 따라 행렬  $\mathbf{A}$ 를  $N$ 의 함수로 풀어 쓰면 다음과 같다.

$$\mathbf{A}_N = \sum_{i=1}^N \begin{pmatrix} X_{N,i}^2 & X_{N,i} Y_{N,i} & X_{N,i} Z_{N,i} \\ Y_{N,i} X_{N,i} & Y_{N,i}^2 & Y_{N,i} Z_{N,i} \\ Z_{N,i} X_{N,i} & Z_{N,i} Y_{N,i} & Z_{N,i}^2 \end{pmatrix}. \quad (3.19)$$

이 행렬은  $W_N$ 로 나누었을 때 공분산 행렬(covariance matrix)이 된다.

$\mathbf{A}_N$ 의 가장 작은 고윳값을  $\lambda_{min}$ 라고 할 때  $S$ 의 최솟값은 바로  $\lambda_{min}$ 가 됨을 식 (3.15)으로 부터 알 수 있다. 또한 최소제곱의 제곱근인 RMS는 다음과 같다.

$$\text{RMS} = \sqrt{\frac{\lambda_{min}}{\langle w \rangle_N (N-2)}} \quad (3.20)$$

$\lambda_{min}$ 를  $W_N$  가 아닌  $(W_N - 2\langle w \rangle_N)$ 로 나누는 이유는 평면을 만드는데 필요한 자유도가 2개 소모 되기 때문이다. 모든 가중치가 1인 경우에는  $(N-2)$ 로 나누어야 하지만 이 경우에는 자유도 하나 당 가중치의 평균을 빼주기 때문에  $(W_N - 2W_N/N)$ 로 나눈다. 즉,  $\langle w \rangle_N (N-2)$ 으로 나눈다.

## 3.2 가만있어봐라

행렬  $\mathbf{A}$ 의 성분을 정리하면 다음과 같다.

$$\begin{aligned} (\mathbf{A}_N)_{11} &= \sum_{i=1}^N X_{N,i}^2 \\ &= \sum_{i=1}^N w_i (x_i - \langle x \rangle_N)^2 \\ &= \sum_{i=1}^N w_i (x_i^2 - 2x_i \langle x \rangle_N + \langle x \rangle_N^2) \\ &= \sum_{i=1}^N w_i x_i^2 - 2\langle x \rangle_N \sum_{i=1}^N w_i x_i + \langle x \rangle_N^2 \sum_{i=1}^N w_i \\ &= W_N \langle x^2 \rangle_N - 2W_N \langle x \rangle_N^2 + W_N \langle x \rangle_N^2 \\ &= W_N (\langle x^2 \rangle_N - \langle x \rangle_N^2). \end{aligned} \quad (3.21)$$

$$\begin{aligned}
(\mathbf{A}_N)_{12} &= \sum_{i=1}^N X_{N,i} Y_{N,i} \\
&= \sum_{i=1}^N w_i (x_i - \langle x \rangle_N) (y_i - \langle y \rangle_N) \\
&= \sum_{i=1}^N w_i (x_i y_i + \langle y \rangle_N \langle x \rangle_N - x_i \langle y \rangle_N - y_i \langle x \rangle_N) \\
&= \sum_{i=1}^N w_i x_i y_i + \langle x \rangle_N \langle y \rangle_N \sum_{i=1}^N w_i - \langle y \rangle_N \sum_{i=1}^N w_i x_i - \langle x \rangle_N \sum_{i=1}^N w_i y_i \\
&= W_N \langle xy \rangle_N + W_N \langle x \rangle_N \langle y \rangle_N - W_N \langle y \rangle_N \langle x \rangle_N - W_N \langle x \rangle_N \langle y \rangle_N \\
&= W_N (\langle xy \rangle_N - \langle x \rangle_N \langle y \rangle_N).
\end{aligned} \tag{3.22}$$

행렬  $\mathbf{A}$ 는 대칭 행렬이며 각 행에 따라서  $x, y, z$ 의 순서만 바뀌기 때문에 위 두 성분을 이용하여 다른 성분들을 쉽게 알 수 있다.

이제 기존 데이터에서 다른 데이터를 추가할 때 행렬  $\mathbf{A}$ 가 어떻게 변하는지 알아보자. 각 성분들은 다음과 같다.

$$(\mathbf{A}_{N+1})_{11} = W_{N+1} (\langle x^2 \rangle_{N+1} - \langle x \rangle_{N+1}^2), \tag{3.23}$$

$$(\mathbf{A}_{N+1})_{22} = W_{N+1} (\langle y^2 \rangle_{N+1} - \langle y \rangle_{N+1}^2), \tag{3.24}$$

$$(\mathbf{A}_{N+1})_{33} = W_{N+1} (\langle z^2 \rangle_{N+1} - \langle z \rangle_{N+1}^2), \tag{3.25}$$

$$(\mathbf{A}_{N+1})_{12} = W_{N+1} (\langle xy \rangle_{N+1} - \langle x \rangle_{N+1} \langle y \rangle_{N+1}), \tag{3.26}$$

$$(\mathbf{A}_{N+1})_{13} = W_{N+1} (\langle xz \rangle_{N+1} - \langle x \rangle_{N+1} \langle z \rangle_{N+1}), \tag{3.27}$$

$$(\mathbf{A}_{N+1})_{23} = W_{N+1} (\langle yz \rangle_{N+1} - \langle y \rangle_{N+1} \langle z \rangle_{N+1}). \tag{3.28}$$

각 성분들을 이루는 기댓값들은 다음과 같이 기존 기댓값을 이용하여 구할 수 있다.

$$\begin{aligned}
\langle x \rangle_{N+1} &= \frac{1}{W_{N+1}} \sum_{i=1}^{N+1} w_i x_i \\
&= \frac{1}{W_{N+1}} \left( \sum_{i=1}^N w_i x_i + w_{N+1} x_{N+1} \right) \\
&= \frac{1}{W_{N+1}} (W_N \langle x \rangle_N + w_{N+1} x_{N+1}).
\end{aligned} \tag{3.29}$$

$$\begin{aligned}
\langle x^2 \rangle_{N+1} &= \frac{1}{W_{N+1}} \sum_{i=1}^{N+1} w_i x_i^2 \\
&= \frac{1}{W_{N+1}} \left( \sum_{i=1}^N w_i x_i^2 + w_{N+1} x_{N+1}^2 \right) \\
&= \frac{1}{W_{N+1}} (W_N \langle x^2 \rangle_N + w_{N+1} x_{N+1}^2).
\end{aligned} \tag{3.30}$$

$$\begin{aligned}
\langle xy \rangle_{N+1} &= \frac{1}{W_{N+1}} \sum_{i=1}^{N+1} w_i x_i y_i \\
&= \frac{1}{W_{N+1}} \left( \sum_{i=1}^N w_i x_i y_i + w_{N+1} x_{N+1} y_{N+1} \right) \\
&= \frac{1}{W_{N+1}} \left( W_N \langle xy \rangle_N + w_{N+1} x_{N+1} y_{N+1} \right).
\end{aligned} \tag{3.31}$$

$k$  번째 데이터를 하나 제거 하는 경우는 다음과 같다.

$$(\mathbf{A}_{N,!k})_{11} = W_{N,!k} \left( \langle x^2 \rangle_{N,!k} - \langle x \rangle_{N,!k}^2 \right), \tag{3.32}$$

$$(\mathbf{A}_{N,!k})_{22} = W_{N,!k} \left( \langle y^2 \rangle_{N,!k} - \langle y \rangle_{N,!k}^2 \right), \tag{3.33}$$

$$(\mathbf{A}_{N,!k})_{33} = W_{N,!k} \left( \langle z^2 \rangle_{N,!k} - \langle z \rangle_{N,!k}^2 \right), \tag{3.34}$$

$$(\mathbf{A}_{N,!k})_{12} = W_{N,!k} \left( \langle xy \rangle_{N,!k} - \langle x \rangle_{N,!k} \langle y \rangle_{N,!k} \right), \tag{3.35}$$

$$(\mathbf{A}_{N,!k})_{13} = W_{N,!k} \left( \langle xz \rangle_{N,!k} - \langle x \rangle_{N,!k} \langle z \rangle_{N,!k} \right), \tag{3.36}$$

$$(\mathbf{A}_{N,!k})_{23} = W_{N,!k} \left( \langle yz \rangle_{N,!k} - \langle y \rangle_{N,!k} \langle z \rangle_{N,!k} \right). \tag{3.37}$$

위에서와 같이 기댓값은 아래와 같이 구할 수 있다.

$$\begin{aligned}
\langle x \rangle_{N,!k} &= \frac{1}{W_{N,!k}} \sum_{i=1, i \neq k}^N w_i x_i \\
&= \frac{1}{W_{N,!k}} \left( \sum_{i=1}^N w_i x_i - w_k x_k \right) \\
&= \frac{1}{W_{N,!k}} \left( W_N \langle x \rangle_N - w_k x_k \right).
\end{aligned} \tag{3.38}$$

$$\begin{aligned}
\langle x^2 \rangle_{N,!k} &= \frac{1}{W_{N,!k}} \sum_{i=1, i \neq k}^N w_i x_i^2 \\
&= \frac{1}{W_{N,!k}} \left( \sum_{i=1}^N w_i x_i^2 - w_k x_k^2 \right) \\
&= \frac{1}{W_{N,!k}} \left( W_N \langle x^2 \rangle_N - w_k x_k^2 \right).
\end{aligned} \tag{3.39}$$

$$\begin{aligned}
\langle xy \rangle_{N,!k} &= \frac{1}{W_{N,!k}} \sum_{i=1, i \neq k}^N w_i x_i y_i \\
&= \frac{1}{W_{N,!k}} \left( \sum_{i=1}^N w_i x_i y_i - w_k x_k y_k \right) \\
&= \frac{1}{W_{N,!k}} \left( W_N \langle xy \rangle_N - w_k x_k y_k \right).
\end{aligned} \tag{3.40}$$

### 3.3 직선 피팅

점  $(x_0, y_0, z_0)$ 을 지나가고  $(a, b, c)$ 의 방향 벡터를 가지는 직선

$$x = x_0 + at$$

$$y = y_0 + bt$$

$$z = z_0 + ct$$

과 점  $(x_i, y_i, z_i)$  사이의 수직 거리는 다음과 같다.

$$D_i(x_0, y_0, z_0, a, b, c) = \left( \begin{array}{c} (c(y_i - y_0) - b(z_i - z_0))^2 \\ + (a(z_i - z_0) - c(x_i - x_0))^2 \\ + (b(x_i - x_0) - a(y_i - y_0))^2 \end{array} \right)^{1/2} \quad (3.41)$$

우리는 점과 직선사이 거리 제곱의 합을 최소화 할 것이므로  $S$ 는 다음과 같이 쓸 수 있다.

$$S(x_0, y_0, z_0, a, b, c) = w_i \sum_{i=1}^N \left( \begin{array}{c} (c(y_i - y_0) - b(z_i - z_0))^2 \\ + (a(z_i - z_0) - c(x_i - x_0))^2 \\ + (b(x_i - x_0) - a(y_i - y_0))^2 \end{array} \right) \quad (3.42)$$

이제  $S$ 를  $x_0, y_0, z_0$ 에 대해서 각각 최소화 하면 ( $\partial S / \partial x_0 = 0, \partial S / \partial y_0 = 0, \partial S / \partial z_0 = 0$ ) 다음식을 얻을 수 있다.

$$\frac{x_0 - \langle x \rangle_N}{a} = \frac{y_0 - \langle y \rangle_N}{b} = \frac{z_0 - \langle z \rangle_N}{c} \quad (3.43)$$

여기서  $\langle x \rangle_N, \langle y \rangle_N, \langle z \rangle_N$ 는 식 (3.4)와 같다. 위 식은  $(x_0, y_0, z_0)$ 가  $(\langle x \rangle_N, \langle y \rangle_N, \langle z \rangle_N)$ 일 때 만족한다. 따라서 우리가 구하고자 하는 직선은 데이터의 중심점을 지나간다.

데이터 점을  $R_i$ , 데이터의 중심점을  $C$ , 우리가 구하고자 하는 직선을  $L$ , 그 직선에 수직하고 점  $C$ 를 포함하는 평면을  $P$ , 그리고  $D(\alpha, \beta)$ 를  $\alpha$ 와  $\beta$  사이의 거리라고 할 때, 피타고라스의 정리를 이용하면 다음과 같이 쓸 수 있다.

$$\sum_{i=1}^N D(R_i, L)^2 = \sum_{i=1}^N D(R_i, C)^2 - \sum_{i=1}^N D(R_i, P)^2 \quad (3.44)$$

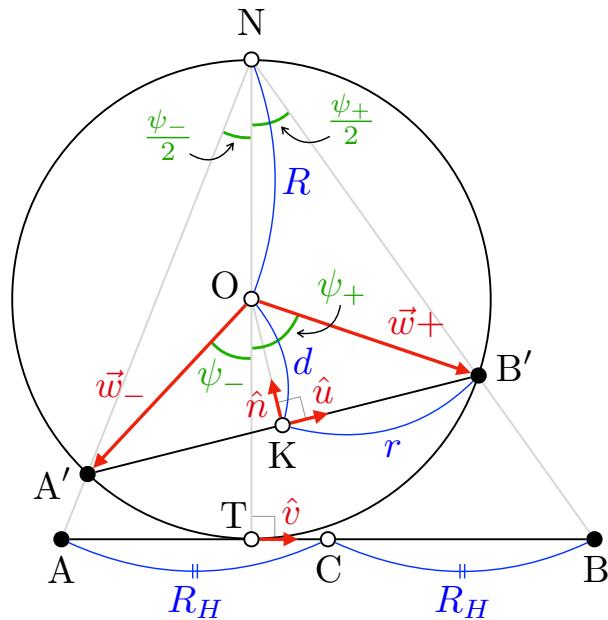
위의  $\sum D(R_i, C)^2$ 는 상수임을 알 수 있다. 즉  $S (= \sum D(R_i, L)^2)$ 는  $\sum D(R_i, P)^2$ 를 최대화 하므로써 구할 수 있다. 이 때  $\sum D(R_i, P)^2$ 는 3.1절의  $S$ (식 (3.2), (3.9))와 같으므로 행렬  $\mathbf{A}$ (식 (3.19))의 가장 큰 고윳값을 찾는 문제로 귀결된다.

## 제 4 장

# 수직 거리 회귀와 Stereographic projection을 이용한 원 피팅

### 4.1 Stereographic projection

### 4.2 원 파라미터



$$n_x x + n_y y + n_z z = k \quad (4.1)$$

$$(4.2)$$

$$k = \hat{n} \cdot \langle \mathbf{x} \rangle_{\mathbf{M}} \quad (4.3)$$

$$d = |k - \hat{n} \cdot \mathbf{x}_{\mathbf{RS}}| \quad (4.4)$$

$$\hat{u} = \frac{l_y \vec{l} + m_y \vec{m}}{\sqrt{l_y^2 + m_y^2}} \quad (4.5)$$

$$\hat{v} = \frac{u_x^2 \hat{x} + u_z^2 \hat{z}}{\sqrt{u_x^2 + u_z^2}} \quad (4.6)$$

$$\vec{w}_{\pm} = -d\hat{n} \pm \sqrt{R_{RS}^2 - d^2} \hat{u} \quad (4.7)$$

$$\psi_{\pm} = \arctan \frac{|\hat{v} \cdot w_{\pm}|}{w_{\pm,y}} \quad (4.8)$$

$$R_{\pm} = R_{RS} \left( \tan \frac{\psi_+}{2} \pm \tan \frac{\psi_-}{2} \right) \quad (4.9)$$

$$R_H = R_+ \quad (4.10)$$

$$\mathbf{x}_H = R_- \hat{v} + \mathbf{x}_{\mathbf{RS}} \quad (4.11)$$

## 참고 문헌

- [1] The Math Forum - Line of Best Fit For Points in Three Dimensional Space (<http://mathforum.org/library/drmath/view/69103.html>).
- [2] The Math Forum - Orthogonal Distance Regression Planes (<http://mathforum.org/library/drmath/view/63765.html>).
- [3] Singular value decomposition ([https://en.wikipedia.org/wiki/Singular\\_value\\_decomposition](https://en.wikipedia.org/wiki/Singular_value_decomposition)).